

UTN - FRBA	CATEDRA DE INVESTIGACIÓN OPERATIVA	ING. INDUSTRIAL
	Apunte Teórico – Filas de Espera	Año: 2020

Contenido

Introducción y Aplicaciones	2
Definiciones.....	2
Estructuras básicas del Modelo de Filas de Espera.....	6
Cola Simple, un Canal de Atención.....	6
Cola Simple, Múltiples Canales de Atención	7
Cola Múltiple, una para cada Canal de Atención	8
Notación de Kendall	8
Nomenclatura a utilizar.....	9
Ley de Little	11
Anexo – Procesos de Poisson	12
Anexo – Fórmulas.....	15
M/M/1.....	15
M/M/x>1	16
CT: Costo del servicio	17

UTN - FRBA	CATEDRA DE INVESTIGACIÓN OPERATIVA	ING. INDUSTRIAL
	Apunte Teórico – Filas de Espera	Año: 2020

Introducción y Aplicaciones

La espera es considerada como una experiencia desagradable porque insume uno de los recursos más valiosos para la gente: “El tiempo”. Varias veces al día una persona debe esperar. Si bien hay que esperar en las paradas de los colectivos, en el dentista, en los bancos, en las estaciones de servicio, en las autopistas para pagar el peaje, en las cajas de los supermercados, también hay que hacerlo al intentar establecer una comunicación telefónica con los proveedores de servicios o cuando se espera la libreta con la nota de un examen final en la facultad. También esperan los productos que deben ser sometidos a un proceso de fabricación en una planta industrial, las máquinas que se han descompuesto y deben ser reparadas, los aviones que intentan utilizar las pistas de aterrizaje y los camiones que deben cargar o descargar productos terminados. En todos los casos, el tiempo desperdiciado se traduce en un alto costo.

Por otro lado, cuando la paciencia llega a su límite, la gente se va a otro lugar. Sin embargo, un servicio muy rápido tendría un costo muy elevado por lo que para satisfacer al cliente es necesario encontrar un balance adecuado entre la espera y el costo.

Entonces, si tenemos en cuenta que la satisfacción del cliente por un servicio viene dada por la diferencia entre la percepción del servicio recibido y las expectativas del cliente tendremos que tener en cuenta lo siguiente:

- Ley de Harper
 - No importa en qué cola me ponga, la otra siempre avanzará más rápido;
 - Si me cambio de cola, aquella en que estaba antes empezará a avanzar más rápido.
- Enunciados de Maister
 - El tiempo ocioso se percibe más que el tiempo ocupado;
 - La ansiedad incrementa la percepción de espera;
 - La espera en cola se percibe más que la espera dentro del proceso de servicio;
 - Los tiempos de espera sin explicaciones se perciben más que los explicados;
 - Las esperas con sensación de injusticia se perciben más;
 - Las esperas individuales son más pesadas que las colectivas.

Teniendo en cuenta lo antes mencionado, en la teoría de colas estudiaremos un conjunto de modelos matemáticos que describen sistemas de filas de espera particulares siendo su objetivo encontrar el estado estable del sistema y determinar una capacidad apropiada.

Por supuesto, existen muchos sistemas de colas distintos, algunos son muy especiales y otros se ajustan a modelos más generales. Nosotros nos estaremos ocupando de estos últimos.

Definiciones

Los fenómenos de “espera” pueden describirse como sistemas integrados por uno o más “centros de atención” en donde se brinda un servicio. Cada centro de atención (llamado también “unidad de servicio”) es, a su vez, un sistema constituido por:

- Canales, que son las entidades que prestan el servicio;
- Clientes, que son las entidades que reciben el servicio.

UTN - FRBA	CATEDRA DE INVESTIGACIÓN OPERATIVA	ING. INDUSTRIAL
	Apunte Teórico – Filas de Espera	Año: 2020

Los clientes, que provienen de una población con determinadas características, llegan al sistema e ingresan a él para recibir el servicio. Si hay algún canal desocupado en el momento de ingreso, el cliente recibirá el servicio inmediatamente; en caso contrario, esperará su turno en una cola. Es decir, *las colas se forman cuando la demanda de un servicio dado en un intervalo de tiempo excede la capacidad para proveerlo.*


Una vez atendidos, los clientes abandonan el centro y pueden pasar a otro centro de atención en el mismo sistema, o bien retirarse, ya sea definitivamente o parcialmente (incorporándose nuevamente a la población fuente de la que proviene, para recibir nuevamente el servicio en un futuro).

El problema que enfrenta con frecuencia el administrador del sistema es establecer un balance apropiado entre los costos asociados a la espera de los usuarios y los costos asociados a la mejora del servicio (más servidores, mayor velocidad de atención, etc.) Este problema resultaría sencillo si los clientes arribaran a intervalos fijos y conocidos y si, además, la duración del servicio fuera también determinística. Por ejemplo, en una línea de montaje (en donde el grado de aleatoriedad del proceso de fabricación es típicamente bajo), se puede llegar a balancear exactamente la capacidad de servicio con la llegada de clientes (en este caso: productos). Sin embargo, en la mayoría de procesos de atención, los tiempos entre arribo de clientes y los tiempos de servicios no son predecibles. En estas condiciones se aplica la denominada “teoría de colas”.

Dentro de la teoría de colas el número de casos diferentes que se pueden presentar es infinito, por lo que estudiaremos solo aquellos sistemas que describan los procesos más generales, y que son los que pueden formularse como cadenas de Markov de primer orden. Además, analizaremos estos modelos para describir el comportamiento de los sistemas en régimen permanente, a través de variables tales como la longitud promedio de cola, el tiempo de espera promedio de un cliente para recibir el servicio, el tiempo de permanencia en el sistema, etc. Esta información, conjuntamente con los costos relevantes, permitirá describir el sistema para beneficiar el proceso de toma de decisiones dentro de una empresa dada.

Para el análisis en régimen transitorio de los modelos de filas de espera, y para situaciones de gran complejidad, los métodos cuantitativos de solución analítica dejan de ser eficaces. En esos casos, es posible obtener mejores resultados mediante las técnicas de “Simulación”.

Entonces, teniendo en cuenta el esquema general de un sistema de Filas de Espera:



UTN - FRBA	CATEDRA DE INVESTIGACIÓN OPERATIVA	ING. INDUSTRIAL
	Apunte Teórico – Filas de Espera	Año: 2020

Diremos que:

- **Población**

Es el conjunto de usuarios potenciales del sistema. El tamaño de la población puede ser finito o infinito. Si la población es finita pero lo suficientemente grande como para que la llegada de un cliente no afecte el valor de la probabilidad de otra llegada, se considera infinito.

- **Arribos**

La llegada de clientes al sistema puede ser determinística, es decir a intervalos entre arribos conocidos (ya sean iguales o desiguales) o aleatoria, es decir a intervalos desiguales que responden a una determinada distribución de probabilidad.

En la mayoría de los sistemas de cola del mundo los procesos de arribo de clientes son aleatorios. Además, a menudo los intervalos entre llegadas son estadísticamente independientes y estacionarios a lo largo de prolongados periodos de tiempo, por lo que se pueden suponer Poissonianos. En particular, salvo mención en contrario, en los sistemas que formularemos en este contexto supondremos que los procesos de arribo son del tipo Poisson.

- **Impaciencia**

Cuando la población de clientes es de seres humanos se puede producir el denominado fenómeno de "Impaciencia". La impaciencia se verifica cuando algunos usuarios que arriban al sistema se retiran sin recibir el servicio porque consideran que el tiempo de espera será suficientemente largo.

Se pueden distinguir dos tipos de Impaciencia:

- La que se da cuando un cliente que arriba, observa la cantidad de gente que está delante de él esperando y en función de ello toma la decisión de incorporarse o no al sistema.
- La que se da cuando un cliente que arriba, ingresa al sistema, y al cabo de un tiempo toma la decisión de seguir esperando o no.

El primer caso se manifiesta, en general, cuando los clientes tienen una experiencia en el funcionamiento del sistema. Antes de incorporarse el cliente estima, en base a la cantidad de gente que está adentro del sistema y a la velocidad de atención de los canales, cuánto tiempo deberá esperar hasta ser atendido.

El segundo tipo de impaciencia se presenta normalmente cuando los usuarios no tienen conocimiento previo de la operatividad del sistema, por lo que la cantidad de clientes esperando no es un parámetro de estimación suficiente. En consecuencia, el cliente se incorpora y, a medida que transcurre el tiempo, se va formando una mejor idea de cuánto tiempo le falta aún para recibir su servicio, y en función de ello decide abandonar el sistema o seguir esperando.

- **Capacidad**

Es el número máximo de clientes que pueden permanecer en el sistema simultáneamente (en espera y atendándose).

Cuando un sistema no tiene límite en el número de clientes permitidos tiene capacidad infinita y se dice que el sistema es de "cola infinita" o "capacidad infinita". En caso contrario el sistema es de "Cola o capacidad finita".

UTN - FRBA	CATEDRA DE INVESTIGACIÓN OPERATIVA	ING. INDUSTRIAL
	Apunte Teórico – Filas de Espera	Año: 2020

Si un cliente que arriba a un sistema de capacidad finita encuentra que éste está completo, no puede ingresar, por lo que se retirará sin recibir el servicio. Si al cliente se le permitiera esperar afuera, significaría que la capacidad real del sistema es mayor a la física, por lo que debe considerarse como capacidad a la cantidad total máxima de usuarios capaces de permanecer en atención o cola simultáneamente, ya sea dentro o fuera de las instalaciones físicas del sistema.

- **Modo de arribo**

Los usuarios pueden llegar en forma individual o en masa. En la mayoría de los sistemas que estudiaremos se hará la suposición de que los procesos de llegada son del tipo Poisson, lo que implica arribos individuales.

Aún en muchos casos en donde se producen arribos masivos, se puede considerar al grupo como un cliente individual a los efectos de los cálculos. Un ejemplo de ello es el de un restaurante en donde la unidad considerada como cliente puede ser cada grupo de comensales que compartirá la mesa.

- **Prioridad de atención**

Existen diversos criterios de atención en lo que se refiere al orden de selección de clientes para brindar el servicio. Ellos son:

- **Base FIFO (First in, First out):** Los clientes se atienden según el orden de llegada; es decir, el que primero llega, primero es atendido. Esta disciplina de atención es la más habitual y constituye la cola típica, en donde el último cliente que arriba al sistema se ubica en el último lugar de la cola.
Cabe mencionar, que no siempre existe una cola física, pero ocurre como si la hubiera. Por ejemplo, si al llegar a un comercio, se saca un número, el proceso de atención es exactamente el mismo que habría si la cola fuera real.
- **Base LIFO (Last in, First out):** En este caso, el último individuo que arriba es el primero en ser atendido. La línea de espera en este caso se denomina “Pila”. Un ejemplo de esta disciplina de atención lo constituye un sistema de control de calidad de un producto que se va apilando para ser inspeccionado. El inspector selecciona siempre el producto que está posicionado más arriba en la pila.
- **Base SIRO (Service in random order):** Es una selección aleatoria de los clientes para brindarles el servicio. Supongamos un telar en donde las máquinas se traban en forma aleatoria. Los operarios destrabadores deambulan por la planta, y cuando observan una máquina parada la destraban. Aquí, los operarios no están teniendo en consideración cual fue la máquina que se trabó primero.
- **Base con PRIORIDADES:** Se establecen criterios de atención conforme con los atributos de los clientes. Por ejemplo, En un aeropuerto en donde los aviones (clientes) utilizan las pistas (canales) para despegar y para aterrizar, típicamente tienen prioridad de uso aquellos que están necesitando sistemas de prioridad para los aviones de mayor envergadura que están sobrevolando el aeropuerto con respecto con los de menor tamaño. Y, por supuesto, también aquellos que soliciten la pista aterrizar en condiciones de emergencia, tendrán prioridad absoluta.

Las prioridades pueden ser relativas o absolutas. Supongamos un sistema con dos tipos de prioridad (A y B), en donde A tiene prioridad de servicio respecto a B. En

UTN - FRBA	CATEDRA DE INVESTIGACIÓN OPERATIVA	ING. INDUSTRIAL
	Apunte Teórico – Filas de Espera	Año: 2020

un sistema de un solo canal con prioridad relativa, si se está atendiendo a un cliente tipo B cuando llega un A, se termina de atender al cliente B, antes de comenzar la atención del A. En cambio si la prioridad es absoluta, en el momento del arribo de un A, se deja de atender al B, se le da el servicio al A, y luego se continua el servicio que se le estaba realizando al B.

- **Duración del servicio**

El tiempo requerido por un canal para atender a un cliente puede ser una variable determinística (tiempos constantes o variables) o aleatoria con una distribución de probabilidad conocida.

En la mayoría de los sistemas de colas del mundo real los procesos de servicios de clientes son aleatorios. Además, los tiempos de servicios son estadísticamente independientes y estacionales a lo largo de prolongados periodos de tiempo, por lo que se pueden suponer Poissonianos. En los sistemas que formularemos en este contexto, supondremos que los procesos de servicio son de tipo Exponencial.


- **Modo de atención**

Un canal puede realizar servicios en forma simple o múltiple (en masa). En la mayoría de los sistemas reales el modo de atención es individual, por lo que en general haremos esta suposición en los modelos matemáticos que desarrollaremos.

En muchos casos prácticos de servicios masivos es factible hacer la suposición de atención individual, asumiendo simplemente que el grupo constituye un cliente a los efectos de los cálculos.

Estructuras básicas del Modelo de Filas de Espera

Cola Simple, un Canal de Atención



Supuestos:

La probabilidad de arribo de clientes al sistema es de tipo Poisson.

UTN - FRBA	CATEDRA DE INVESTIGACIÓN OPERATIVA	ING. INDUSTRIAL
	Apunte Teórico – Filas de Espera	Año: 2020

La probabilidad de dar servicio es del tipo Exponencial.

El sistema se encuentra en condiciones estables; es decir, ha alcanzado condiciones de equilibrio de sus variantes (Régimen permanente).

Los clientes que llegan al sistema forman una cola simple.

La disciplina de atención es FIFO.

Se dispone de un canal de atención.


La capacidad del sistema es ilimitada (cola infinita) o limitada (cola finita) dependiendo del problema analizado.

Los clientes que llegan al sistema no presentan impaciencia.

La población de clientes potenciales del sistema es infinita.

En el caso de que la capacidad sea finita, la fila no podrá tener un largo mayor al especificado en las condiciones establecidas por el caso.

Cola Simple, Múltiples Canales de Atención



Supuestos:

La probabilidad de arribo de clientes al sistema es de tipo Poisson.

La probabilidad de dar servicio es del tipo Exponencial.

El sistema se encuentra en condiciones estables; es decir, ha alcanzado condiciones de equilibrio de sus variantes (Régimen permanente).

Los clientes que llegan al sistema forman una cola simple.

La disciplina de atención es FIFO.

Se dispone de múltiples canales de atención.

La capacidad del sistema es ilimitada (cola infinita) o limitada (cola finita) dependiendo del problema analizado.


Los clientes que llegan al sistema no presentan impaciencia.

La población de clientes potenciales del sistema es infinita.

UTN - FRBA	CATEDRA DE INVESTIGACIÓN OPERATIVA	ING. INDUSTRIAL
	Apunte Teórico – Filas de Espera	Año: 2020

En el caso de que la capacidad sea finita, la fila no podrá tener un largo mayor al especificado en las condiciones establecidas por el caso.

Cola Múltiple, una para cada Canal de Atención



Éste último caso puede considerarse como un sistema constituido por varios centros de un canal simple o analizarlo aplicando los conceptos de nacimiento y muerte dentro de una Cadena de Markov con parámetro t continuo homogénea.

Supuestos:

La probabilidad de arribo de clientes al sistema es de tipo Poisson.

La probabilidad de dar servicio es del tipo Exponencial.

El sistema se encuentra en condiciones estables; es decir, ha alcanzado condiciones de equilibrio de sus variantes (Régimen permanente).

Los clientes que llegan al sistema forman una cola ser atendido en alguno de los canales de atención existentes.

La disciplina de atención es FIFO.

Se dispone de más de un canal de atención.

La capacidad del sistema es ilimitada (cola infinita) o limitada (cola finita) dependiendo del problema analizado.

Los clientes que llegan al sistema no presentan impaciencia.

La población de clientes potenciales del sistema es infinita.

En el caso de que la capacidad sea finita, la fila no podrá tener un largo mayor al especificado en las condiciones establecidas por el caso.

Notación de Kendall

David G. Kendall introdujo una notación de colas A/B/C en 1953. Ha sido usada desde entonces y luego extendida a **1/2/3/(4/5/6)** donde los números se reemplazan con:

1. Un código que describe el proceso de llegada. Los usados son:
 - a. M para "Markoviano" (la tasa de llegadas sigue una distribución de Poisson)
 - b. D para unos tiempos entre llegadas "determinísticas"
 - c. G para una "distribución general" de los tiempos entre llegadas

UTN - FRBA	CATEDRA DE INVESTIGACIÓN OPERATIVA	ING. INDUSTRIAL
	Apunte Teórico – Filas de Espera	Año: 2020

- d. E para una distribución Erlang
2. Un código similar que representa el proceso de servicio (tiempo de servicio). Se usan los mismos símbolos.
3. El número de canales de servicio (o servidores)
4. La capacidad del sistema, o el número máximo de clientes permitidos en el sistema incluyendo esos en servicio. Cuando el número está al máximo, las llegadas siguientes son rechazadas. Un caso particular de esta situación es el modelo M/M/n/n o Erlang-B, en el cual no hay cola de espera, sino n recursos (servidores) y hasta n usuarios como máximo; si llega el usuario n+1, es rechazado. Este último modelo es el que se aplica en telefonía convencional. Otro caso particular es el modelo Erlang-C o M/M/n, donde la capacidad del sistema es ilimitada, aunque haya sólo n recursos; en caso de llegar el recurso número n+1, pasará a una cola de espera, pero no es rechazado.
5. El orden de prioridad en la que los trabajos en la cola son servidos:
 - a. First Come First Served (FCFS) ó First In First Out (FIFO),
 - b. Last Come First Served (LCFS) o Last In First Out (LIFO),
 - c. Service In Random Order (SIRO) y
 - d. Processor Sharing.
6. El tamaño del origen de las llamadas. El tamaño de la población desde donde los clientes vienen. Esto limita la tasa de llegadas.

Nomenclatura a utilizar

J : Número promedio de clientes fuera del sistema (aplicable a población finita)

n : Estado del sistema (es la cantidad de clientes que hay dentro del sistema en un momento determinado)

N : Capacidad del sistema (Cantidad máxima de clientes que puede haber en el sistema, tanto en los canales como en la cola)

k : Cantidad de canales dispuestos en paralelo en la unidad operativa de atención

H : Número promedio de canales activos

λ : Número promedio de clientes que arriban al sistema por unidad de tiempo (tasa promedio de arribos)

T_a : Intervalo promedio entre arribos de clientes (llamado también tiempo promedio de arribos)

$$T_a = \frac{1}{\lambda}$$

$\bar{\lambda}$: Tasa promedio de ingreso de clientes al sistema.

$$\bar{\lambda} = \sum_{n=0}^N \lambda_n \cdot P_{(n)}$$

$\bar{R}$: Tasa promedio de clientes rechazados (por capacidad finita o por impaciencia)

$$\bar{R} = \lambda - \bar{\lambda}$$

UTN - FRBA	CATEDRA DE INVESTIGACIÓN OPERATIVA	ING. INDUSTRIAL
	Apunte Teórico – Filas de Espera	Año: 2020

PR : Porcentajes de rechazos del sistema

$$PR = \frac{\bar{R}}{\lambda}$$

μ : Número promedio de clientes que puede atender un canal por unidad de tiempo (velocidad promedio de atención)

T_s : Duración promedio del servicio (o tiempo promedio de atención)

$$T_s = \frac{1}{\mu}$$

$\bar{\mu}$: Tasa promedio de egreso de clientes del sistema.

$$\bar{\mu} = \sum_{n=0}^N \mu_n \cdot P_{(n)}$$

$\bar{A}$: Tasa promedio de clientes que abandonan el sistema sin recibir el servicio

$$\bar{\lambda} = \mu + \bar{A}$$

PAB : Porcentajes de abandonados del sistema

$$PAB = \frac{\bar{A}}{\bar{\lambda}}$$

ρ : Factor de transito (o de tráfico)

$$\rho = \frac{\lambda}{\mu}$$

$p_{(n)}$: Probabilidad de que el sistema se encuentre en el estado n .

$P_{(i/n)}$: Probabilidad de que un cliente que arriba al sistema ingrese a él cuando el estado del sistema es " n "

$\omega_c(t)$: Probabilidad de que un cliente tenga que esperar un tiempo superior a " t " en la cola.

$$\omega_c(t) = P_{(W_c > t)}$$

$\omega(t)$: Probabilidad de que un cliente tenga que permanecer un tiempo superior a " t " en el sistema.

$$\omega(t) = P_{(W > t)}$$

L : Longitud promedio del sistema (número esperado de clientes dentro del sistema)

$$L = \sum_{n=0}^N n \cdot P_{(n)}$$

W : Tiempo promedio de permanencia en el sistema de un cliente.

L_c : Longitud promedio de la cola (número esperado de clientes esperando ser atendidos)

$$L_c = \sum_{M+1}^N (n - M) \cdot P_{(n)}$$

W_c : Tiempo promedio de espera en cola de un cliente.

x : Factor de servicio de un sistema de población finita

$$x = \frac{T_s}{T_s + U}$$

F : Factor de eficiencia de un sistema de población finita

$$F = \frac{T_s + U}{T_s + U + W_c}$$

UTN - FRBA	CATEDRA DE INVESTIGACIÓN OPERATIVA	ING. INDUSTRIAL
	Apunte Teórico – Filas de Espera	Año: 2020

CT: Costo del servicio

$$CT = L * \$L + k * \$H$$

Ley de Little

Asumiendo que λ_n es constante y adopta valor λ para todo n, se obtiene que:

$$L = \lambda \times W$$

Y por lo tanto $L_q = \lambda \times W_q$

Por otro lado, suponiendo que el tiempo medio de servicio es una constante ($1/\mu$) para todo $n \geq 1$ encontraremos que:

$$W = W_q + T_s$$

Entonces $L = L_q + \rho$

Estas ecuaciones son conocidas como Ley de Little.

UTN - FRBA	CATEDRA DE INVESTIGACIÓN OPERATIVA	ING. INDUSTRIAL
	Apunte Teórico – Filas de Espera	Año: 2020

Anexo – Procesos de Poisson

Los procesos de Poisson son procesos Markovianos, es decir aquellos que describen fenómenos aleatorios de sistemas dinámicos que evolucionan a través de un parámetro “t” (denominado “continuo”). En los procesos de Poisson tenemos un continuo (en general el tiempo) sobre el que se van dando eventos en forma estadísticamente independiente y con independencia del comienzo del parámetro.


Los procesos Poissonianos tienen dos distribuciones que la describen:

- La distribución Poisson en donde la variable es el número de ventas que se producen en un intervalo determinado de continuo;
- La distribución Gamma en la que la variable es el intervalo de continuo necesario para que se verifique un número determinado de eventos. En particular, cuando la variable es el intervalo de continuo requerido para que se verifique un número discreto de eventos, la distribución se conoce con el nombre de distribución Erlang. Más particularmente cuando la variable es el intervalo de continuo necesario para que se verifique un solo suceso, la distribución es conocida como distribución exponencial.

Distribución Poisson: La probabilidad de que se produzcan “n” eventos en un intervalo “t” está dada por:

$$p(n) = \frac{(\lambda \Delta t)^n \cdot e^{-\lambda \Delta t}}{n!} \quad \text{Siendo } n = 0, 1, 2, \dots, \text{ y } \lambda > 0.$$

La media de esta distribución es $a = \lambda \cdot t$, y el desvío estándar $\sigma = \sqrt{\lambda \cdot t}$. En la unidad de tiempo (es decir para $t = 1$), la media de esta distribución es $a = \lambda$.



Los procesos de Poisson tienen la particularidad de que la probabilidad de que se dé un evento en un intervalo de tiempo muy pequeño es λt y la probabilidad de que no se dé el evento es $1 - \lambda \Delta t$.

UTN - FRBA	CATEDRA DE INVESTIGACIÓN OPERATIVA	ING. INDUSTRIAL
	Apunte Teórico – Filas de Espera	Año: 2020


Distribución Gamma: Sustenta una relación con la Distribución de Poisson que surge de intercambiar parámetro por variable. Puede asumir una gran variedad de formas por la que se puede acomodar a diversos conjuntos de datos observados.

En particular, cuando la variable es el intervalo de continuo requerido para que se verifique un número discreto de eventos, la distribución se conoce con el nombre de distribución Erlang, que posee un parámetro de forma k que determina su desviación estándar:

$$\sigma = \frac{1}{\sqrt{k}} \text{media}$$

Si $k = 1$, entonces la distribución Erlang es igual a la exponencial

Si $k = \infty$, entonces la distribución Erlang es igual a la distribución degenerada con tiempos constantes




Distribución	Desviación estándar
Constante	0
Erlang, $k = 1$	media
Erlang, $k = 2$	
Erlang, $k = 4$	$1/2 \text{ media}$
Erlang, $k = 8$	
Erlang, $k = 16$	$1/4 \text{ media}$
Erlang, cualquier k	

En los sistemas de colas interesa la distribución exponencial, en donde la variable se refiere a la porción de continuo que debe transcurrir para que se verifique un suceso (es decir, la porción de continuo entre dos sucesos). La función distribución de probabilidad de la distribución exponencial está dada por la siguiente expresión:

UTN - FRBA	CATEDRA DE INVESTIGACIÓN OPERATIVA	ING. INDUSTRIAL
	Apunte Teórico – Filas de Espera	Año: 2020

$$f(t) = \lambda \cdot e^{-\lambda t} \quad \text{Cuya media es } \frac{1}{\lambda}$$

Gráficamente



UTN - FRBA	CATEDRA DE INVESTIGACIÓN OPERATIVA	ING. INDUSTRIAL
	Apunte Teórico – Filas de Espera	Año: 2020

Anexo – Fórmulas

M/M/1

Capacidad del sistema: infinito (en caso de ser finito usaremos los Procesos de Nacimiento y Muerte)

Fuente de clientes: infinito

λ : Número promedio de clientes que arriban al sistema por unidad de tiempo (tasa promedio de arribos)

μ : Número promedio de clientes que puede atender un canal por unidad de tiempo (velocidad promedio de atención)

- Factor de Tránsito < 1

$$\rho = \frac{\lambda}{\mu}$$

- Probabilidad de que no haya unidades en el sistema

$$P_0 = 1 - \rho$$

- Número promedio de unidades en la fila de espera

$$L_q = \lambda W_q = \frac{\lambda^2}{\mu(\mu - \lambda)}$$

- Número promedio de unidades en el sistema

$$L = \lambda W = L_q + \rho = \frac{\lambda}{\mu - \lambda}$$

- Tiempo de espera promedio en la fila de espera

$$W_q = \frac{L_q}{\lambda} = \frac{\rho}{\mu(1 - \rho)}$$

- Tiempo promedio para atravesar el sistema

$$W = W_q + T_s = W_q + \frac{1}{\mu} = \frac{1}{\mu(1 - \rho)}$$

- Probabilidad de que una unidad que llega tenga que esperar para ser atendida

$$P_w = \frac{\lambda}{\mu}$$

- Probabilidad de que haya n unidades en el sistema

$$P_n = \left(\frac{\lambda}{\mu}\right)^n P_0$$

UTN - FRBA	CATEDRA DE INVESTIGACIÓN OPERATIVA	ING. INDUSTRIAL
	Apunte Teórico – Filas de Espera	Año: 2020

M/M/x>1

Capacidad del sistema: infinito (en caso de ser finito usaremos los Procesos de Nacimiento y Muerte)

Fuente de clientes: infinito

λ : Número promedio de clientes que arriban al sistema por unidad de tiempo (tasa promedio de arribos)

μ : Número promedio de clientes que puede atender un canal por unidad de tiempo (velocidad promedio de atención)

k : Cantidad de canales dispuestos en paralelo en la unidad operativa de atención

- Factor de Tránsito

$$k\mu > \lambda$$

- Probabilidad de que no haya unidades en el sistema

$$P_0 = \frac{1}{\sum_{n=0}^{k-1} \frac{(\lambda/\mu)^n}{n!} + \frac{(\lambda/\mu)^k}{k!} \left(\frac{k\mu}{k\mu - \lambda} \right)}$$

- Número promedio de unidades en la fila de espera

$$L_q = \frac{(\lambda/\mu)^k \lambda \mu}{(k-1)! (k\mu - \lambda)^2} P_0$$

- Tiempo de espera promedio en la fila de espera

$$W_q = \frac{L_q}{\lambda}$$

- Tiempo promedio para atravesar el sistema

$$W = W_q + T_s = W_q + \frac{1}{\mu}$$

- Probabilidad de que una unidad que llega tenga que esperar para ser atendida

$$P_w = \frac{1}{k!} \left(\frac{\lambda}{\mu} \right)^k \left(\frac{k\mu}{k\mu - \lambda} \right) P_0$$

- Probabilidad de que haya n unidades en el sistema

- Cuando $n \leq k$

$$P_n = \frac{(\lambda/\mu)^n}{n!} P_0$$

- Cuando $n > k$

$$P_n = \frac{(\lambda/\mu)^n}{k! k^{n-k}} P_0$$

UTN - FRBA	CATEDRA DE INVESTIGACIÓN OPERATIVA	ING. INDUSTRIAL
	Apunte Teórico – Filas de Espera	Año: 2020

CT: Costo del servicio

$$CT = L * \$L + k * \$H$$

$\$L$ = Costo de la espera por periodo para cada unidad

L = Número promedio de unidades en el sistema

$\$H$ = Costo del servicio por periodo para cada unidad

k = Número de canales